RedesNeuronales VelasquezLuna EliJafet

June 11, 2024

1 Ejercicio

Repetir el ejercicio pero sin normalizar la entrada y exploren el resultado

```
[1]: from sklearn.datasets import fetch_openml
    from sklearn.preprocessing import normalize

X,y = fetch_openml('mnist_784', as_frame=False, return_X_y=True)

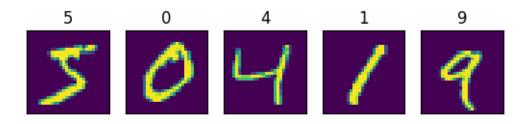
# EJERCICIO: quitar la siguiente linea:
    # X = normalize(X)

import matplotlib.pyplot as plt

imagenes_mostrar = X.reshape([-1,28,28])[:5]
    labels_mostrar = y[:5]
    for i, (img,label) in enumerate(zip(imagenes_mostrar,labels_mostrar)):
        plt.subplot(151 + i) #esto es para que las ponga lado a lado, se interpreta_u=cada digito (1: renglon, 5:columnas, x: el indice en el que se va poniendo)
        plt.imshow(img)
        plt.xticks([])
        plt.yticks([])
        plt.title(label)
```

/usr/local/lib/python3.10/dist-packages/sklearn/datasets/_openml.py:968:
FutureWarning: The default value of `parser` will change from `'liac-arff'` to `'auto'` in 1.4. You can set `parser='auto'` to silence this warning. Therefore, an `ImportError` will be raised from 1.4 if the dataset is dense and pandas is not installed. Note that the pandas parser may return different data types. See the Notes Section in fetch_openml's API doc for details.

warn(



```
[2]: import tensorflow as tf
```

1.0.1 Preparación de Dataset

```
[3]: # Separación del dataset

X_train = X[:60000]

X_test = X[60000:]

y_train = y[:60000]

y_test = y[60000:]
```

```
[4]: X_train = tf.constant(X_train,dtype=tf.float32)
X_test = tf.constant(X_test,dtype=tf.float32)
y_train = tf.constant(y_train,dtype=tf.float32)
y_test = tf.constant(y_test,dtype=tf.float32)
```

1.0.2 Modelo Multicapa

```
[5]: entradas = tf.keras.Input(shape=(784,))
capa1 = tf.keras.layers.Dense(100,activation="relu")(entradas)
capa2 = tf.keras.layers.Dense(10,activation="softmax")(capa1)
```

```
[6]: modelo = tf.keras.Model(inputs=entradas,outputs=capa2)
```

[7]: modelo.summary()

Model: "model"

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 784)]	0
dense (Dense)	(None, 100)	78500
dense_1 (Dense)	(None, 10)	1010

Total params: 79510 (310.59 KB)
Trainable params: 79510 (310.59 KB)
Non-trainable params: 0 (0.00 Byte)

```
[8]: modelo.compile(optimizer="SGD", loss="sparse_categorical_crossentropy",
```

```
metrics="accuracy")
[9]: modelo.fit(X_train,y_train,epochs=10)
  Epoch 1/10
  1875/1875 [============== ] - 6s 3ms/step - loss: 74.9187 -
  accuracy: 0.1272
  Epoch 2/10
  accuracy: 0.1131
  Epoch 3/10
  accuracy: 0.1168
  Epoch 4/10
  accuracy: 0.1711
  Epoch 5/10
  1875/1875 [============ ] - 7s 4ms/step - loss: 2.0951 -
  accuracy: 0.1902
  Epoch 6/10
  accuracy: 0.1921
  Epoch 7/10
  accuracy: 0.1437
  Epoch 8/10
  accuracy: 0.1515
  Epoch 9/10
  accuracy: 0.1411
  Epoch 10/10
  accuracy: 0.1967
[9]: <keras.src.callbacks.History at 0x7a1b9387e200>
[10]: modelo.evaluate(X_test,y_test)
  accuracy: 0.1841
[10]: [2.1363043785095215, 0.18410000205039978]
[11]: modelo.predict(X_test[0:1])
```

1/1 [======] - Os 92ms/step

- 1. Repetir el ejercicio visto en clase pero omitiendo la normalización en la entrada y explorar el resultado.
- ¿Qué ocurre? La función de pérdida y Accuracy no convergen.
- ¿Por qué? Si la entrada no está normalizada, el cálculo del gradiente descendiente se puede encontrar con pendientes tan grandes que, al tratar de optimizar los pesos, provoquen que la función de pérdida no converga. Asimismo, puede generar valores tan grandes que son omitidos, produciendo inestabilidad en las neuronas.

2 Explorar con diferentes combinaciones de capas y funciones de activación.

2.0.1 Sin función de activación en Capa 1

Model: "model_1"

modelo.summary()

Layer (type)	Output Shape	Param #
input_2 (InputLayer)	[(None, 784)]	0
dense_2 (Dense)	(None, 100)	78500
dense_3 (Dense)	(None, 10)	1010

```
Trainable params: 79510 (310.59 KB)
 Non-trainable params: 0 (0.00 Byte)
[16]: modelo.compile(optimizer="SGD",
       loss="sparse_categorical_crossentropy",
       metrics="accuracy")
  modelo.fit(X_train,y_train,epochs=10)
 Epoch 1/10
 0.0987
 Epoch 2/10
 0.0987
 Epoch 3/10
 0.0987
 Epoch 4/10
 0.0987
 Epoch 5/10
 0.0987
 Epoch 6/10
 0.0987
 Epoch 7/10
 0.0987
 Epoch 8/10
 0.0987
 Epoch 9/10
 0.0987
 Epoch 10/10
 0.0987
[16]: <keras.src.callbacks.History at 0x7a1b2ea95b40>
[17]: modelo.evaluate(X_test,y_test)
```

Total params: 79510 (310.59 KB)

0.0980

[17]: [nan, 0.09799999743700027]

- ¿Qué ocurre? La función de pérdida arroja valores NaN.
- ¿Por qué? Si la entrada no está normalizada, el cálculo del gradiente descendiente se puede encontrar con pendientes tan grandes que, al tratar de optimizar los pesos, provoquen que la función de pérdida genera valores tan grandes que son omitidos, produciendo inestabilidad en las neuronas.
- Volver a preparar datos con X normalizado

```
[18]: X = normalize(X)

[19]: # Separación del dataset
    X_train = X[:60000]
    X_test = X[60000:]
    y_train = y[:60000:]

[20]: X_train = tf.constant(X_train,dtype=tf.float32)
    X_test = tf.constant(X_test,dtype=tf.float32)
    y_train = tf.constant(y_train,dtype=tf.float32)
    y_train = tf.constant(y_train,dtype=tf.float32)
    y_test = tf.constant(y_test,dtype=tf.float32)

[21]: entradas = tf.keras.Input(shape=(784,))
    capa1 = tf.keras.layers.Dense(100)(entradas)
    capa2 = tf.keras.layers.Dense(10,activation="softmax")(capa1)

[22]: modelo = tf.keras.Model(inputs=entradas,outputs=capa2)
    modelo.summary()
```

Model: "model_2"

Layer (type)	Output Shape	Param #		
input_3 (InputLayer)	[(None, 784)]	0		
dense_4 (Dense)	(None, 100)	78500		
dense_5 (Dense)	(None, 10)	1010		
Total params: 79510 (310.59 KB) Trainable params: 79510 (310.59 KB)				

Non-trainable params: 0 (0.00 Byte)

```
[23]: modelo.compile(optimizer="SGD",
           loss="sparse_categorical_crossentropy",
           metrics="accuracy")
   modelo.fit(X_train,y_train,epochs=10)
   Epoch 1/10
   accuracy: 0.5834
   Epoch 2/10
   accuracy: 0.7620
   Epoch 3/10
   1875/1875 [============ ] - 7s 4ms/step - loss: 0.9297 -
   accuracy: 0.8160
   Epoch 4/10
   1875/1875 [============= ] - 6s 3ms/step - loss: 0.7096 -
   accuracy: 0.8407
   Epoch 5/10
   1875/1875 [============= ] - 6s 3ms/step - loss: 0.5964 -
   accuracy: 0.8560
   Epoch 6/10
   accuracy: 0.8673
   Epoch 7/10
   accuracy: 0.8750
   Epoch 8/10
   1875/1875 [============= ] - 8s 4ms/step - loss: 0.4518 -
   accuracy: 0.8806
   Epoch 9/10
   accuracy: 0.8845
   Epoch 10/10
   accuracy: 0.8883
```

[23]: <keras.src.callbacks.History at 0x7a1b2f61d2a0>

• ¿Qué ocurre? La función de pérdida y el accuracy convergen cais tan rápido como si no hubiera función de activación "relu" en la capa1.

2.0.2 Agregando función de activación antes del Softmax

```
[27]: entradas = tf.keras.Input(shape=(784,))
capa1 = tf.keras.layers.Dense(100, activation="relu")(entradas)
# Aplicar ReLU explicitamente antes de Softmax
```

```
capa_intermedia = tf.keras.layers.Dense(10)(capa1)
    capa_relu = tf.keras.activations.relu(capa_intermedia)
    capa2 = tf.keras.layers.Activation("softmax")(capa_relu)
[28]: modelo = tf.keras.Model(inputs=entradas,outputs=capa2)
    modelo.summary()
    Model: "model 4"
    Layer (type)
                   Output Shape
                                            Param #
    ______
    input_5 (InputLayer)
                         [(None, 784)]
    dense_8 (Dense)
                         (None, 100)
                                             78500
    dense_9 (Dense)
                          (None, 10)
                                             1010
    tf.nn.relu (TFOpLambda)
                          (None, 10)
    activation (Activation)
                          (None, 10)
    Total params: 79510 (310.59 KB)
    Trainable params: 79510 (310.59 KB)
    Non-trainable params: 0 (0.00 Byte)
[29]: modelo.compile(optimizer="SGD",
               loss="sparse_categorical_crossentropy",
               metrics="accuracy")
    modelo.fit(X_train,y_train,epochs=10)
    Epoch 1/10
    accuracy: 0.4935
    Epoch 2/10
    accuracy: 0.6911
    Epoch 3/10
    1875/1875 [============= - - 6s 3ms/step - loss: 1.0891 -
    accuracy: 0.7875
    Epoch 4/10
    accuracy: 0.8272
    Epoch 5/10
    1875/1875 [============= ] - 7s 4ms/step - loss: 0.6517 -
    accuracy: 0.8477
```

[29]: <keras.src.callbacks.History at 0x7a1b2ea8fdf0>

• ¿Qué ocurre? Parece no haber cambios significativos.

2.0.3 Agregando capas y funciones de activación.

```
[32]: entradas = tf.keras.Input(shape=(784,))

capa1 = tf.keras.layers.Dense(100,activation='sigmoid')(entradas)

capa2 = tf.keras.layers.Dense(50,activation='relu')(capa1)

capa3 = tf.keras.layers.Dense(50,activation='tanh')(capa2)

capa2 = tf.keras.layers.Dense(10,activation="softmax")(capa3)
```

```
[33]: modelo = tf.keras.Model(inputs=entradas,outputs=capa2)
modelo.summary()
```

Model: "model_6"

Layer (type)	Output Shape	Param #
input_7 (InputLayer)	[(None, 784)]	0
dense_14 (Dense)	(None, 100)	78500
dense_15 (Dense)	(None, 50)	5050
dense_16 (Dense)	(None, 50)	2550
dense_17 (Dense)	(None, 10)	510
		========

Total params: 86610 (338.32 KB)

```
Trainable params: 86610 (338.32 KB)
  Non-trainable params: 0 (0.00 Byte)
[34]: modelo.compile(optimizer="SGD",
          loss="sparse_categorical_crossentropy",
          metrics="accuracy")
  modelo.fit(X_train,y_train,epochs=10)
  Epoch 1/10
  accuracy: 0.1313
  Epoch 2/10
  accuracy: 0.2215
  Epoch 3/10
  accuracy: 0.3679
  Epoch 4/10
  accuracy: 0.5190
  Epoch 5/10
  accuracy: 0.6705
  Epoch 6/10
  1875/1875 [============= ] - 7s 4ms/step - loss: 0.7893 -
  accuracy: 0.7437
  Epoch 7/10
  1875/1875 [============== ] - 11s 6ms/step - loss: 0.6859 -
  accuracy: 0.7824
  Epoch 8/10
  accuracy: 0.8067
  Epoch 9/10
  accuracy: 0.8213
  Epoch 10/10
```

[34]: <keras.src.callbacks.History at 0x7a1b2ea8c2b0>

accuracy: 0.8333

- ¿Qué ocurre? Tarda más en converger y comienza desde un accuracy muy bajo, con respecto al modelo visto en clase con sólo 2 capas (activación relu y softmax).
- ¿Por qué? Es probable que añadir las capas intermedias con 50 neuronas y funciones de activación como la sigmoide y tanh provocaran que, al realizarse operaciones adicionales, se introduzca ruido o desorden en el resultado y, por tanto, pérdida de información.